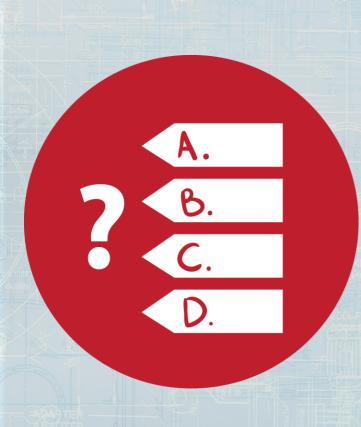


O MODELO RELACIONAL E SEUS CUSTOS





Por que (ainda) usar um SGBDR tradicional



- Eficiência
- Confiabilidade
- Conveniência
 - Modelo de dados simples (relacional)
 - Linguagem de consulta declarativa (SQL)
 - Garantias transacionais
- Armazenamento e acesso seguros
 - para multiusuários
 - para quantidades massivas de dados persistentes



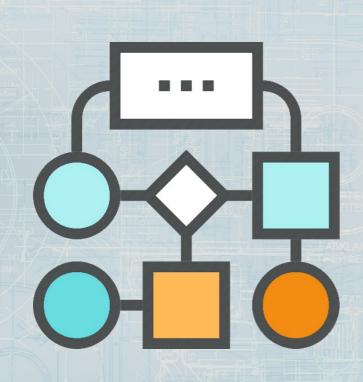
Conveniência × custo



- As conveniências de um SGBDR são garantidas por funcionalidades que vêm embaladas em um "pacote indivisível"
 - No entanto, cada conveniência tem um custo associado
 - Não é possível abrir mão de apenas algumas conveniências que não são necessárias para uma aplicação, a fim de se livrar do respectivo custo
 - É tudo ou nada!



Custo: modelo relacional



- Os dados
 - são organizados em relações
 - têm um formato padronizado, definido pelo esquema
- Há uma álgebra "compreensível" (operações em conjuntos) sobre as relações
 - Base da linguagem de consulta (SQL) "JOINS"
- Mas, e quando os dados não guardam relação entre si ou não se encaixam em um formato previsível?
 - Antes que possam ser carregados em um BD relacional, os dados deverão ser reorganizados

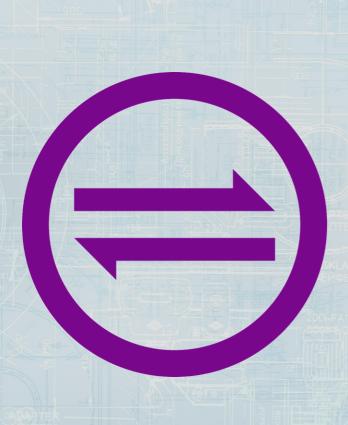
Custo: SQL



- A SQL é uma linguagem de consulta e modificação de dados muito poderosa
 - Inclui seleções, projeções, junções, agregações, operações sobre conjuntos, predicados
- Às vezes, a SQL oferece muito mais funcionalidades do que uma dada aplicação precisa de fato
 - Exemplo: há aplicações que só precisam fazer recuperações simples, baseadas na chave do registro
 - Nesses casos, usar um sistema que implementa uma linguagem de consulta complicada é um custo alto demais para se arcar



Custo: garantias transacionais



- Transações são muito importantes quando há vários usuários acessando os mesmos dados e os requisitos de consistência são rígidos
- Mas em algumas aplicações em que esses requisitos são menos rígidos, até mesmo as garantias mais fracas impostas pelos SGBDRs podem não ser apropriadas
- As garantias transacionais, em qualquer nível, representam uma carga extra de processamento para o servidor



Custo: confiabilidade



- Confiabilidade é algo que queremos em qualquer sistema de BD
- Mas é possível lidar com ela de forma diferente em aplicações executadas em modo batch ou aplicações de análise de dados
 - Nesses casos, na ocorrência de uma falha, uma estratégia viável para garantir a confiabilidade é simplesmente refazer o processamento todo
 - Essa estratégia não é aplicável, por exemplo, às transações online realizadas em um site de vendas de produtos que interage com um SGBD relacional



Custo: dados em grande volume



- É uma das razões para o surgimento dos sistemas NoSQL
- O volume dos dados manipulados hoje em dia é muito maior do que o volume para o qual os SGBDRs tradicionais foram projetados
- Alguns motivos para o aumento do volume de dados:
 - Grande queda do custo de dispositivos de armazenamento secundário
 - Coletas de dados em altas taxas, feitas por sensores em variados tipos de dispositivos (como celulares, câmeras, etc.) e por web sites (como Facebook, Twitter, etc.)



Custo: eficiência



- As aplicações da atualidade têm requisitos de desempenho que são muito mais rígidos que antigamente
- Para aplicações web, eficiência no tempo de resposta é crucial
 - Milhões (e até bilhões) de registros
 - Mesmo para consultas envolvendo operações complexas sobre essa quantidade de registros, o tempo da resposta deve ser menos de 1 segundo



Custo: sobrecargas

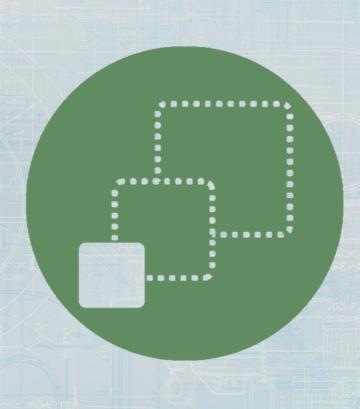


- Principais sobrecargas de SGBDs relacionais:
 - Logging: tudo é gravado duas vezes → uma no disco e outra no log do SGBD
 - Locks: bloqueios para gravação de item de dados (para garantir propriedades transacionais)
 - Latches: bloqueios especiais, para alteração de estruturas de dádos auxiliares do SGBD (ex.: tabela de bloqueios)
 - Gerenciamento de buffer: páginas de disco → memória principal

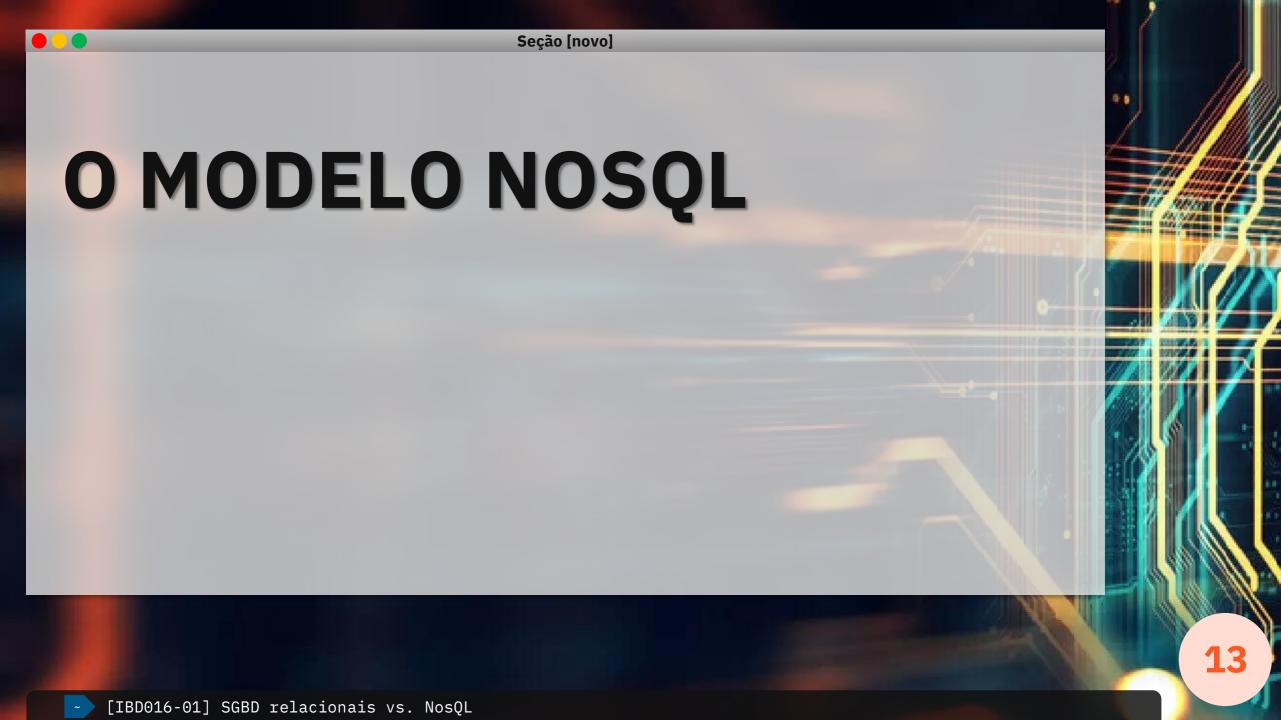




Escalamento em SGBDRs



- SGBDRs também podem ser escaláveis!
- É possível fazer particionamento e replicação de dados em SGBDRs
- Os SGBDRs, desde sua criação, já foram especializados para diferentes necessidades:
 - Data Warehouses (operações de leitura predominam)
 - BDs in-memory
 - BDs distribuídos
 - BDs escaláveis horizontalmente
 - Veja: MySQL Cluster, VoltDB, NuoDB, Clustrix
- Se o desempenho de um SGBDR for "competitivo" com o de um sistema NoSQL, porque abriríamos mão dos benefícios de se ter SQL + consistência ACID?







- 1998 (primeira aparição)
 - Carlo Strozzi
 - SGBD relacional leve, para SOs derivados do UNIX
 - Não implementava a linguagem SQL
- 2009 (reintrodução)
 - Evento organizado por Johan Oskarsson (Last.fm)
 - Popularidade do BigTable/MapReduce (Google) e do DynamoDB (Amazon).
 - Novos sistemas de banco de dados distribuídos e de código aberto



Nomenclatura

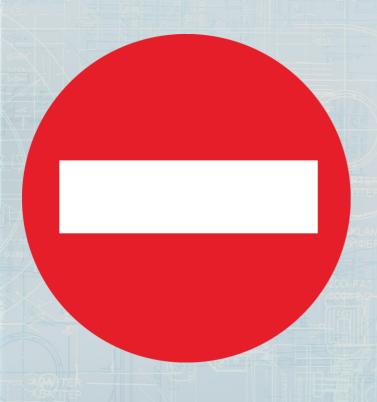
nosq

- Com o tempo, "SQL" tornou-se sinônimo de SGBDs relacionais
- NoSQL é <u>diferente</u> de <u>não usar</u> a linguagem <u>SQL</u>; refere-se a <u>não usar um SGBD relacional</u>
 - Seria até melhor chamar de "NoRel"
- As últimas duas décadas mostraram que nem todo problema de gerenciamento e análise de dados tem por melhor resposta a adoção de um SGBDR tradicional
 - Em outras palavras, nem todo problema de gerenciamento e análise de dados é melhor solucionado usando exclusivamente um SGBDR tradicional
- ♦ Atualmente, NoSQL → "Not Only SQL"






Por que não usar um SGBDR tradicional



- Necessidade de melhor desempenho
- Necessidade de maior flexibilidade



+ Dados, + Eficiência, + Flexibilidade



- Principais motivações para o desenvolvimento dos sistemas NoSQL
- A proposta dos sistemas NoSQL é "sacrificar" alguns dos benefícios providos pelos SGBDRs tradicionais em prol de mais
 - capacidade de armazenamento
 - flexibilidade na representação dos dados
 - eficiência de acesso ao dados





NoSQL: vantagens



- Esquema mais flexível
- Inicialização mais rápida e barata
- Escalabilidade para grandes volumes de dados (tanto para armazenamento, quanto para a eficiência no acesso aos dados)
- Consistência relaxada, que resulta em melhor desempenho e disponibilidade




NoSQL: desvantagens



- A ausência de uma linguagem de consulta declarativa e padronizada
 - Implica em maior esforço para os desenvolvedores, que precisam implementar as operações de manipulação dos dados usando linguagens de programação
- Consistência relaxada
 - Menos garantias com relação à consistência dos dados



NoSQL: características comuns



- A habilidade de escalar horizontalmente operações simples em vários servidores
- A habilidade de replicar e distribuir (particionar) dados em vários servidores
- Substituição da "comunicação" via SQL por APIs simples
- Um modelo de controle de concorrência mais fraco que o das transações ACID usadas nos SGBDRs
- Uso eficiente de índices distribuídos e memória RAM para armazenamento dos dados
- A habilidade de adicionar dinamicamente novos atributos aos registros de dados (ausência de esquema fixo – schemaless)



Definições importantes



"Operações simples"

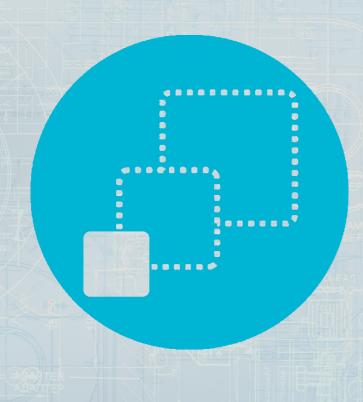
- Busca de um registro por meio de sua chave (key lookup), leituras e escritas de um registro ou de um número pequeno de registros
- Constituem o tipo de operação mais frequente nas aplicações web atuais

"Escalabilidade horizontal"

- Habilidade de distribuir os dados e o processamento de operações simples em vários servidores (nós), sem o compartilhamento de RAM ou disco entre os servidores → arquitetura shared nothing
- Esse tipo de escalabilidade geralmente é mais barata que a vertical, principalmente quando usa commodity hardware
- ➤ Obs.: Escalabilidade vertical → ocorre quando o SGBD usa vários cores que compartilham a mesma RAM e disco, ou seja, o SGBD está em uma única máquina



Escalabilidade horizontal



- Pode ser feita de duas maneiras:
 - Particionando os dados (sharding) entre os nós
 - Particionamento horizontal: cada nó armazena um subconjunto das "linhas" do BD
 - Particionamento vertical: cada nó armazena um subconjunto das "colunas" do BD
 - Replicando os dados nos nós
 - Possibilita que um grande número de operações simples (principalmente consultas) sejam realizadas a cada segundo -> paralelização



Replicação de dados



- Pode ter dois objetivos diferentes (e não mutuamente exclusivos):
 - Tolerância a falhas
 - Balanceamento de carga de operações de acesso a dados
- A propagação das atualizações entre as réplicas pode ser:
 - Assíncrona → garante eventual consistency: não há a garantia de que um dado lido é o mais atual, mas as atualizações serão propagadas para todos os nós em algum momento do tempo
 - **Síncrona** → garante consistência
- Quando a replicação é assíncrona, uma falha em um nó pode causar perda irreversível de dados!



Armazenamento dos dados



- Os dados e os índices podem ser mantidos
 - No disco (HD, SSD)
 - Na memória RAM, com tolerância a falhas por meio de persistência em disco ou replicação



Problemas de consistência



- Tipos de conflitos que podem ocorrer em SGBDRs:
 - Escrita-escrita -> quando dois clientes tentam escrever sobre os mesmos dados ao mesmo tempo
 - **Leitura-escrita** → quando um cliente lê dados inconsistentes no meio da escrita de outro cliente
- Sistemas distribuídos também têm esses conflitos. Ex.:
 - Alterações simultâneas em cópias diferentes de um dado registro
 - Leitura de uma cópia desatualizada



Conflitos e consistência



- Há duas abordagens para evitar conflitos:
 - Pessimista → bloqueia os registros de dados, para evitar os conflitos
 - Otimista → detectam os conflitos e depois os tratam
- Para obter boa consistência, é preciso envolver muitos nós nas operações sobre os dados
 - Mas isso aumenta a latência (tempo de resposta das operações)



Conclusões



- O modelo relacional tradicional não está superado e se adapta bem a aplicações
 - com dados em formato padronizado
 - em que a consistência dos dados é crucial
 - que podem tolerar alguma latência de E/S
- Por outro lado, o modelo NoSQL é indicado quando
 - os dados não se moldam bem ao modelo relacional
 - não é necessária consistência absoluta
 - velocidade de I/O é crucial





Para saber mais



* ELMASRI, R.; NAVATHE, S. B. Sistemas de Banco de Dados: Fundamentos e Aplicações. 7. ed. São Paulo: Pearson, 2019, p. 795-820